

Predicción de Siniestros Viales Fatales en CABA

Pipeline completo de Ciencia de Datos: datos, ETL, EDA, modelado y persistencia

Licenciatura en Ciencia de Datos · Programación Avanzada para Ciencia de Datos

1er Semestre 2026

Matías Bertuna · Mariano Codutti · Christian Lucero

Python

scikit-learn

SQLite

GitHub

FUENTE OFICIAL

Buenos Aires Data · Siniestros viales

data.buenosaires.gob.ar/dataset/victimas-siniestros-viales



BA Data

Datasets Organizaciones Grupos Historias APIs Ingresar

Buenos Aires Data / Dataset

Siniestros viales

Secretaría de Transporte - Subsecretaría de Planificación de la Movilidad - Observatorio de Movilidad y Seguridad Vial

Información sobre siniestros viales ocurridos en la Ciudad desde el año 2019 hasta el 2025.

Recursos del dataset

Formato	Nombre del recurso	Descripción	Vista previa	Descargar
otro	Siniestros viales (víctimas) (XLSX)	Información sobre Homicidios en siniestros viales ocurridos en la Ciudad. Los datos incluyen fecha y ubicación del hecho y tipo de transporte...	VISTA PREVIA	DESCARGAR
CSV	Siniestros viales (víctimas) (CSV)	Información sobre Homicidios en siniestros viales ocurridos en la Ciudad. Los datos incluyen fecha y ubicación del hecho y tipo de transporte...	VISTA PREVIA	DESCARGAR
	Siniestros viales (hechos) (XLSX)			

Hallazgo metodológico: la consigna referencia el recurso de **víctimas**. Al explorar la fuente oficial se identificó también el recurso de **hechos**, necesario para trabajar a nivel siniestro.

CONSTRUCCIÓN DEL DATASET ANALÍTICO



UNIDAD DE ANÁLISIS

1 fila

representa un siniestro vial, no una víctima individual.

RELACIÓN ENTRE TABLAS

1:N

un hecho puede tener una o varias víctimas asociadas.

PROBLEMA DE MACHINE LEARNING

Clasificación binaria

siniestro_fatal

Predecir si un siniestro vial tendrá víctimas fatales.

1

AL MENOS UNA VÍCTIMA FATAL

0

SIN VÍCTIMAS FATALES



Desbalance:
689 fatales · 1,05%



Objetivo:
estimar probabilidad de fatalidad



Métrica crítica:
F1 / Recall sobre clase fatal



2 / 9



RESULTADO DEL ETL

65.818

SINIESTROS

17 variables finales

1 fila = 1 siniestro

Desafío principal:

transformar dos tablas con distinta granularidad en una única base analítica a nivel siniestro.

Decisión metodológica: prevenir data leakage

Se excluyeron variables que describen consecuencias del siniestro o revelan directamente la gravedad.

numero_total_de_victimas

numero_victimas_leve_siniestro

numero_victimas_grave_siniestro

numero_victimas_mortal_siniestro

gravedad_siniestro GRAVEDad_victima

fecha_fallecimiento_victima

FLUJO DE CONSTRUCCIÓN

HECHOS

65.818 filas
1 fila = 1 siniestro

VÍCTIMAS

75.193 filas
1 fila = 1 persona

+



ETL

integración · agregación 1:N · limpieza · transformaciones



Dataset analítico

base final para EDA y modelado predictivo

1 Exploración inicial

Se revisaron duplicados, tipos de datos, faltantes y consistencia entre tablas.

2 Integración 1:N


La tabla Hechos quedó como base y Víctimas se agregó mediante id_siniestro.

3 Variables derivadas

Se construyeron edad promedio, sexo agregado, variables temporales y siniestro_fatal.




3 / 9




HALLAZGOS TEMPORALES QUE GUIARON FEATURE ENGINEERING

TASA DE FATALIDAD POR HORARIO



Decisión: agrupar horas en `franja_horaria`.

TASA DE FATALIDAD POR DÍA




Decisión: crear `tipo_dia` para capturar fines de semana.

INTERACCIONES CON MAYOR FATALIDAD




Conclusión: participantes, contraparte y combinación aportan señal predictiva e interpretación del riesgo.

DISTRIBUCIÓN ESPACIAL · TODOS



DISTRIBUCIÓN ESPACIAL · FATALES



Lectura integrada del EDA

Temporalidad: madrugada y fines de semana motivaron nuevas agrupaciones.

Participantes: las combinaciones muestran diferencias fuertes de riesgo.

Espacio: los siniestros fatales aparecen distribuidos en CABA, sin un único foco dominante.

Pipeline de modelado: imputación de faltantes + One Hot Encoding + ColumnTransformer + estimador dentro de Pipeline para evitar fuga de información.

MODELOS EVALUADOS

Modelo	Accuracy	Precision	Recall	F1
Dummy Classifier	0,9895	0,0000	0,0000	0,0000
Logistic Regression optimizada	0,8640	0,0564	0,7609	0,1050
Decision Tree optimizado	0,9673	0,1051	0,2826	0,1532
Random Forest optimizado	0,9832	0,1971	0,1957	0,1964

Lectura técnica: Logistic Regression detectó más casos fatales, pero con baja precisión. Random Forest ofreció el mejor equilibrio entre Recall, Precision y F1.

COMPARACIÓN POR F1-SCORE

Random Forest **0,1964**

Decision Tree **0,1532**

Logistic Reg. **0,1050**

Dummy **0,0000**

Criterio de selección: se priorizó F1 de la clase fatal, complementado con Recall y Precision. Accuracy se informó, pero no se usó como métrica principal.

Modelo base seleccionado: Random Forest optimizado. La siguiente fase valida si esa elección mejora con modelos avanzados o con mejor representación temporal.

PREGUNTA 1 - ¿MODELOS MÁS COMPLEJOS AYUDARON?

Modelo	F1	Lectura
RF Optimizado	0,1964	referencia experimental
Balanced RF	0,1297	subió Recall, cayó Precision
SMOTE + RF	0,0654	no mejoró el equilibrio
XGBoost	0,1627	cercano, pero no superior

Resultado: aumentar la complejidad algorítmica no superó de manera consistente al Random Forest.

PREGUNTA 2 - ¿FEATURE ENGINEERING TEMPORAL AYUDÓ?

RF Optimizado F1 0,1964

RF + temporal F1 0,2000

+0,0036
DELTA F1
semilla 42

3/5
SEMILLAS
mejoró el F1

Modelo final seleccionado: Random Forest optimizado + variables temporales agrupadas (franja_horaria y tipo_dia).

Aprendizaje: la mejora fue leve pero positiva en promedio (+0,0079 F1). Representar mejor la temporalidad aportó más valor que cambiar de algoritmo.

Objetivo: cumplir la consigna de almacenamiento y dejar trazabilidad de los datos utilizados y los resultados obtenidos.

siniestros_modelado

65.818

Dataset final utilizado para entrenamiento y evaluación.

resultados_modelos

18

Métricas consolidadas de modelos base y avanzados.

predicciones_modelo_final

13.164

Resultados del conjunto de prueba y probabilidades estimadas.

ARQUITECTURA DE PERSISTENCIA



Valor aportado: centraliza los artefactos generados por el proyecto, permite reproducibilidad y trazabilidad de resultados, y facilita consultas posteriores sin reejecutar los notebooks.

Conclusión principal: se construyó un flujo completo de Ciencia de Datos, desde datos públicos hasta modelo predictivo y persistencia en base de datos.

1 Patrones identificables

Variables temporales, geográficas y de participantes aportan información relevante.

2 Modelo defendible

Random Forest con Feature Engineering temporal fue la solución final seleccionada.

3 Evaluación responsable

Se priorizó F1 por el desbalance extremo de clases.

LIMITACIONES

- Clase fatal muy minoritaria.
- Información limitada a variables presentes en los datasets públicos.
- No se incorporaron clima, tránsito, infraestructura vial ni contexto urbano externo.
- El modelo debe interpretarse como apoyo analítico, no como herramienta operativa automática.

TRABAJO FUTURO

- Incorporar variables climáticas y de infraestructura.
- Profundizar ingeniería geográfica.
- Explorar calibración de probabilidades y umbrales de decisión.
- Integrar visualizaciones externas o dashboard de consulta.

CIERRE

La mejora más sólida no vino de hacer el modelo más complejo, sino de representar mejor el problema.

PROGRAMACIÓN AVANZADA PARA CIENCIA DE DATOS

Gracias

¿Preguntas?

Matías Bertuna · Mariano Codutti · Christian Lucero